# Detecção automática de vagas de estacionamento

PDI clássico em C++ e OpenCV, avaliado na base PKLot

Eduardo Morais Silva Martins · Visão Computacional · CEFET-MG · Profª Drª Natália Batista

# Problema e escolha de abordagem

## O problema

Procurar vaga gasta tempo e combustível.

Um sensor por vaga é caro de instalar e manter.

Câmeras de CCTV já existem e enxergam dezenas de vagas.

## Por que PDI clássico

Roda em CPU, sem GPU: viável em edge computing.

Tempo previsível: custo linear nos pixels.

Explicável: dá para ver por que errou.

Sem treinamento, sem sobreajuste a uma câmera.

Base PKLot: 3 pátios, 3 condições climáticas, 12.416 imagens processadas · 2 / 9

# Pipeline: seis etapas, um limiar

### 1 · Tons de cinza

Descarta a cor, mantém o brilho.

### 2 · Filtro gaussiano

3×3, σ = 1: atenua o ruído.

### 3 · Limiarização adaptativa

Bloco 25×25, C = 16: ativa pixels mais escuros que a vizinhança.

### 4 · Dilatação

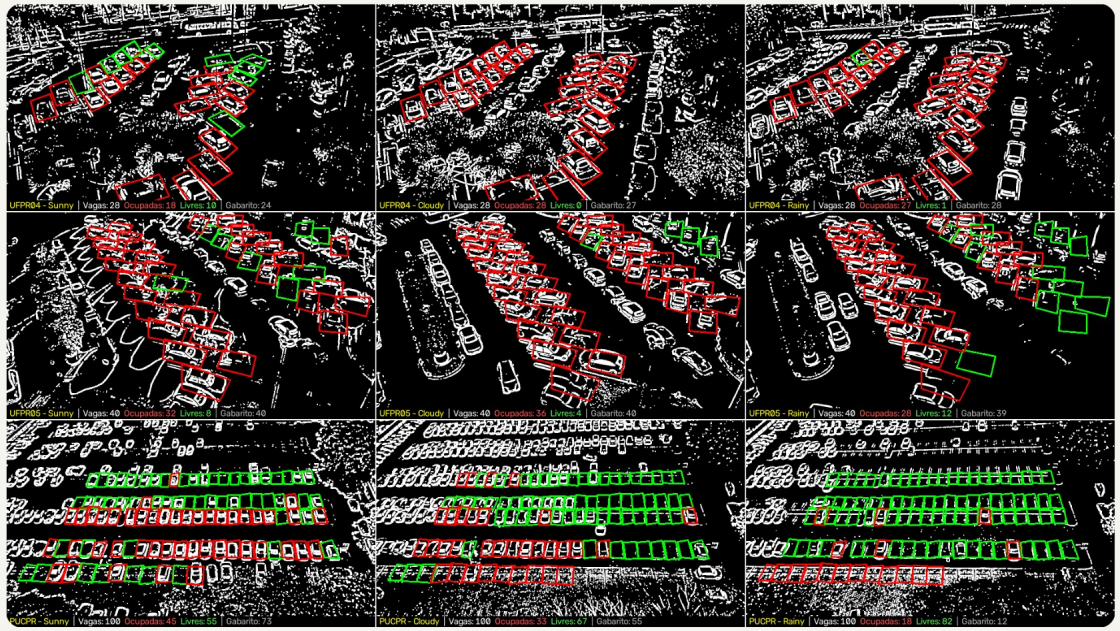
3×3: conecta as arestas do carro.

### 5 · Máscara da vaga

O polígono do XML isola a vaga.

### 6 · Decisão

Pixels ativos ≥ τ ⇒ ocupada.

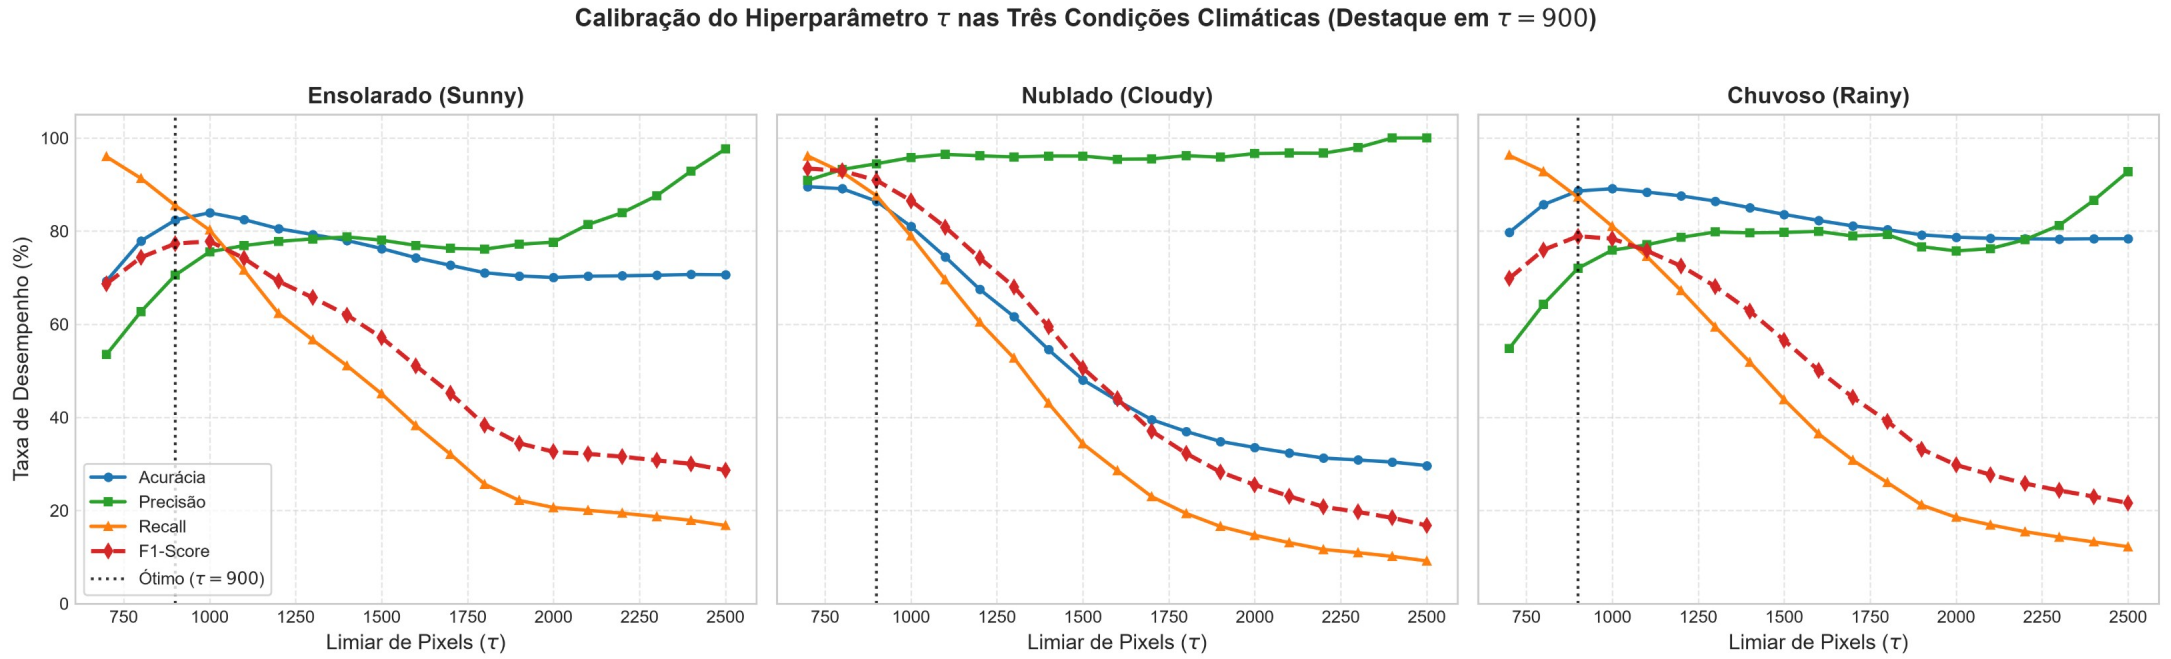



Resultado das etapas 1 a 4 nas 9 amostras: pixels brancos são os ativos contados em cada vaga.

# Calibração: o limiar ótimo é τ = 900

**85,81%** acurácia global no UFPR04

**82,37%** F1-Score médio

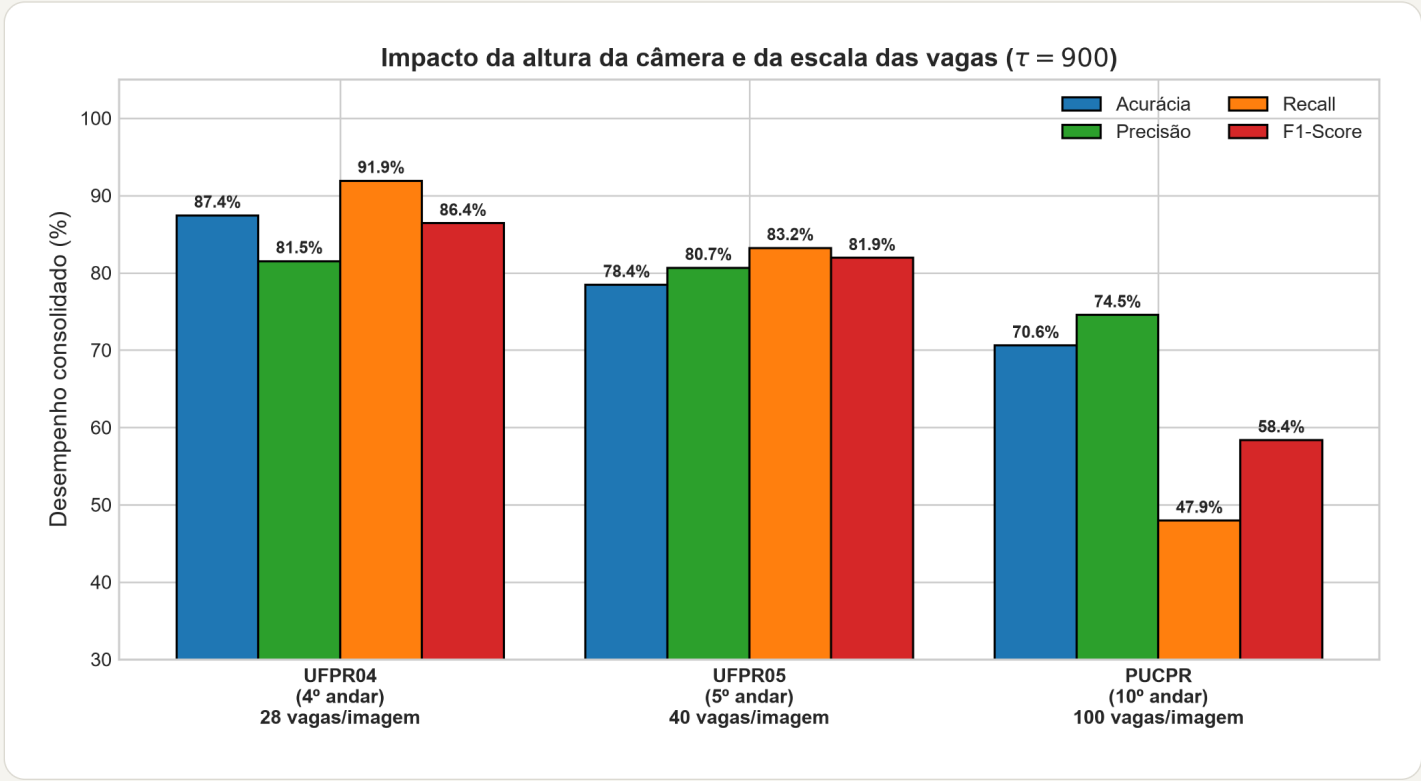


# Benchmark em toda a base PKLot (τ = 900)

**719.528**
vagas avaliadas em 12.416 imagens

**74,89%**
acurácia global (F1 de 70,47%)

**21,2 FPS**
em CPU, um único thread



# Comparação com o baseline do PKLot

| Pátio de teste | Baseline: SVM + LBP/LPQ (treinado no UFPR04) | Este trabalho: 1 limiar (calibrado no UFPR04) | Diferença |
|---|---|---|---|
| UFPR04 (mesmo pátio) | 99,64% | 87,42% | −12,2 p.p. |
| UFPR05 | 88,33% | 78,45% | −9,9 p.p. |
| PUCPR | 88,40% | 70,59% | −17,8 p.p. |

### Mesma tendência

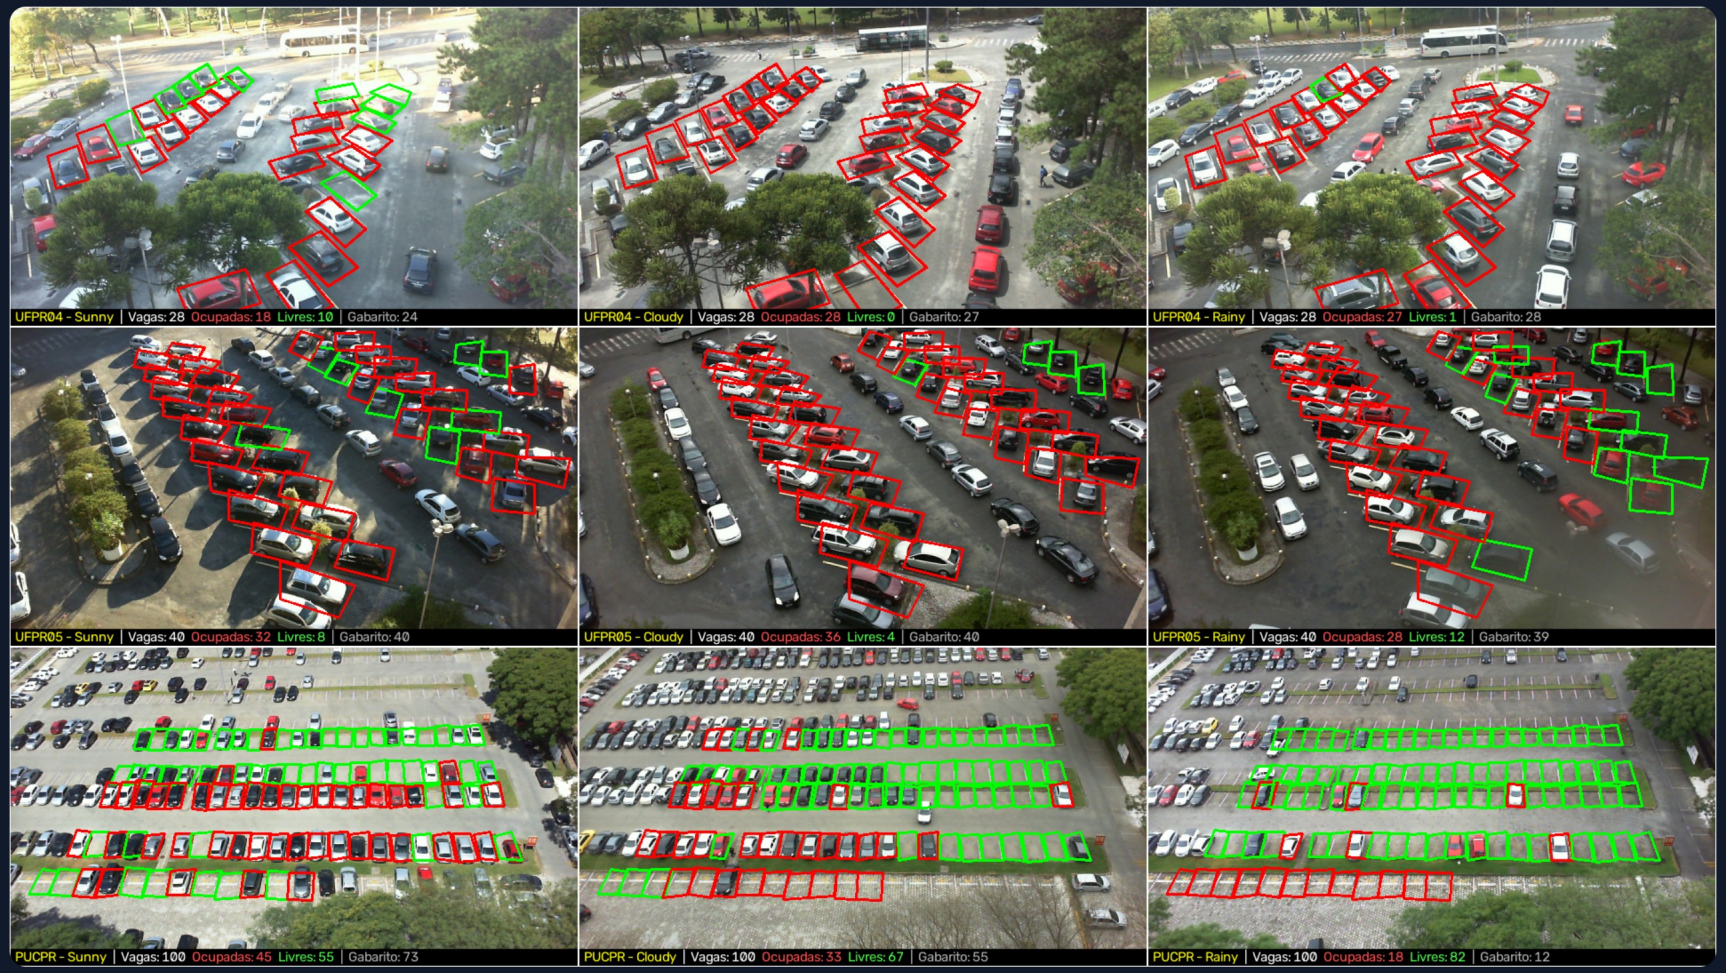
A PUCPR é o pátio mais difícil nos dois trabalhos; o artigo aponta solo, ângulo e altura da câmera.

### Onde o método vale

Sem treinamento, cerca de 21 FPS em CPU e erros que dá para explicar.

Baseline: Almeida et al. (2015), Tabela 3; não é comparação direta, pois ele treina SVMs · 6 / 9

# Exemplos por pátio e clima (τ = 900)




Vermelho = ocupada, verde = livre (predição) · Gabarito = vagas realmente ocupadas · 7 / 9

# Onde e por que o método falha

FALSO POSITIVO

## Sombras duras

A borda da sombra vira um gradiente igual ao de um carro.

FALSO POSITIVO

## Reflexos na chuva

Poças espelham o céu; as gotas geram ruído que a dilatação agrupa.

FALSO POSITIVO

## Textura do piso

Bloquete da PUCPR com pouca luz: a textura gera pixels ativos e é confundida com carro.

FALSO NEGATIVO

## Altura da câmera

PUCPR: 100 vagas em 720p, poucos pixels por vaga. Recall de 47,95%.

**Achado central: τ não é invariante à escala da cena. O limiar deve ser proporcional à área da vaga.**

83% dos falsos negativos (100.056 de 120.145) ocorrem na PUCPR · 8 / 9

# Conclusões

## O que funcionou

87,42% de acurácia no UFPR04, a cerca de 21 FPS em CPU.

Decisões explicáveis e sem treinamento.

## O que não funcionou

Limiar absoluto não transfere entre câmeras (PUCPR).

Sombras, reflexos e a textura do piso viram falsos positivos.

**Obrigado! Perguntas?**